// GUIDA GRATIS · INIZIARE CON NEX N2.5

NEX N2.5, *dalla A alla prova.*

Nex N2.5 è una famiglia di modelli AI «agentici» di Nex-AGI: oltre a rispondere in chat sono addestrati a **usare computer e browser**, scrivere e provare programmi. I pesi sono pubblici e gratuiti con licenza Apache 2.0. Qui trovi cosa è vero, cosa costa davvero e come provarlo oggi, con i comandi presi dalle pagine ufficiali.

1 · Cos'è	tre taglie: mini, Pro, Max	pag. 02
2 · Costi veri	pesi gratis, calcolo no	pag. 03
3 · Prova in chat	OpenRouter, senza codice	pag. 04
4 · Via API	una chiamata con curl o Python	pag. 05
5 · In locale	cosa serve per farlo girare tuo	pag. 06
6 · Come agente	cosa c'è e cosa manca oggi	pag. 07
7 · I benchmark	come leggere il «batte GPT-5.6»	pag. 08
8 · Verifica	come sai che funziona	pag. 09

// COSA TI SERVE

01 Per provarlo (passi 3-4)
Un account OpenRouter con qualche dollaro di credito: lì Nex N2.5 Pro e mini si pagano a consumo, pochi centesimi per molte domande (pag. 03).

02 Per farlo girare tuo (passo 5)
Un server con GPU da data center: il model card indica 2 GPU H100 per il mini, 8 per il Pro. Non gira su un portatile.

03 Per usarlo come agente (passo 6)
Python 3.11+ e un po' di pratica col terminale. Lo strumento ufficiale di Nex per l'uso del computer non è ancora pubblico: ti diciamo cosa usare intanto.

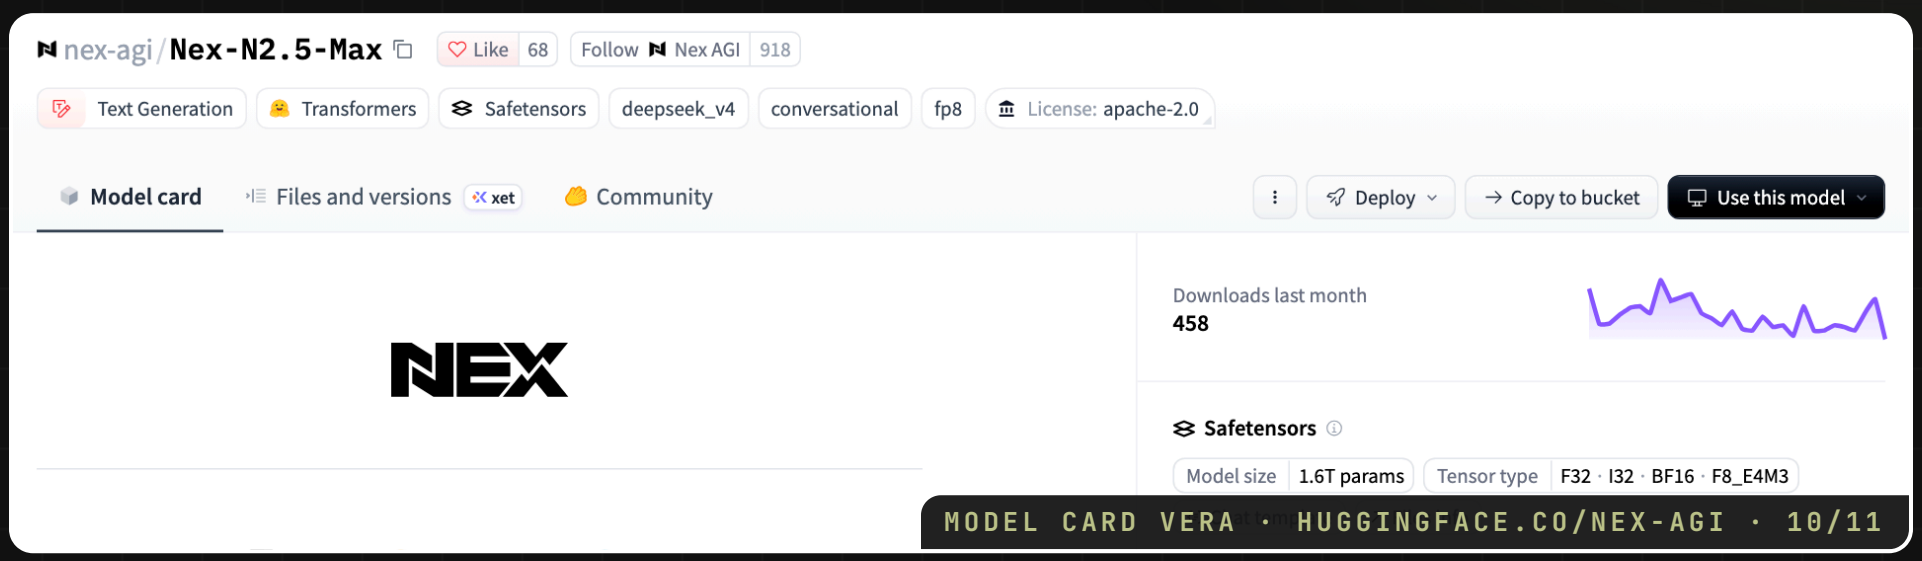
// COME USARLA

Fai i passi in ordine. **«Gratis» vale per i pesi del modello**, non per la potenza di calcolo che serve a usarlo: o paghi un servizio a consumo, o hai l'hardware. Dati, prezzi e comandi controllati sulle pagine ufficiali il 10/11/2026: se qualcosa è cambiato, vale il link della pagina 10.

// PASSO 01 · COS'È NEX N2.5

01 TRE TAGLIE, *un solo nome.*

Perché: «Nex N2.5» non è un modello solo. Le tre versioni hanno dimensioni, capacità e modi d'uso diversi: scegliere quella giusta è il primo passo.



`Nex-N2.5-mini`	35 miliardi di parametri · testo e immagini · uso del computer	`OpenRouter ✓`
`Nex-N2.5-Pro`	397 miliardi · testo e immagini · uso del computer	`OpenRouter ✓`
`Nex-N2.5-Max`	1,6 mila miliardi (1,6T) · solo testo · Mixture-of-Experts	`solo pesi`

01 Cosa dice il model card
mini e Pro partono dalla base multimodale di Nex-N2 con miglioramenti su **uso del computer, navigazione web** e compiti guidati dalla vista; il Max è il loro primo modello addestrato a scala di mille miliardi di parametri.

02 Licenza Apache 2.0
Puoi scaricare i pesi, usarli anche per lavoro e modificarli, mantenendo gli avvisi di licenza. È scritta su ognuna delle tre pagine Hugging Face.

03 Dove trovarli
Hugging Face (`nex-agi/Nex-N2.5-mini` , `-Pro` , `-Max`) e ModelScope. In hosting a consumo: OpenRouter, solo Pro e mini.

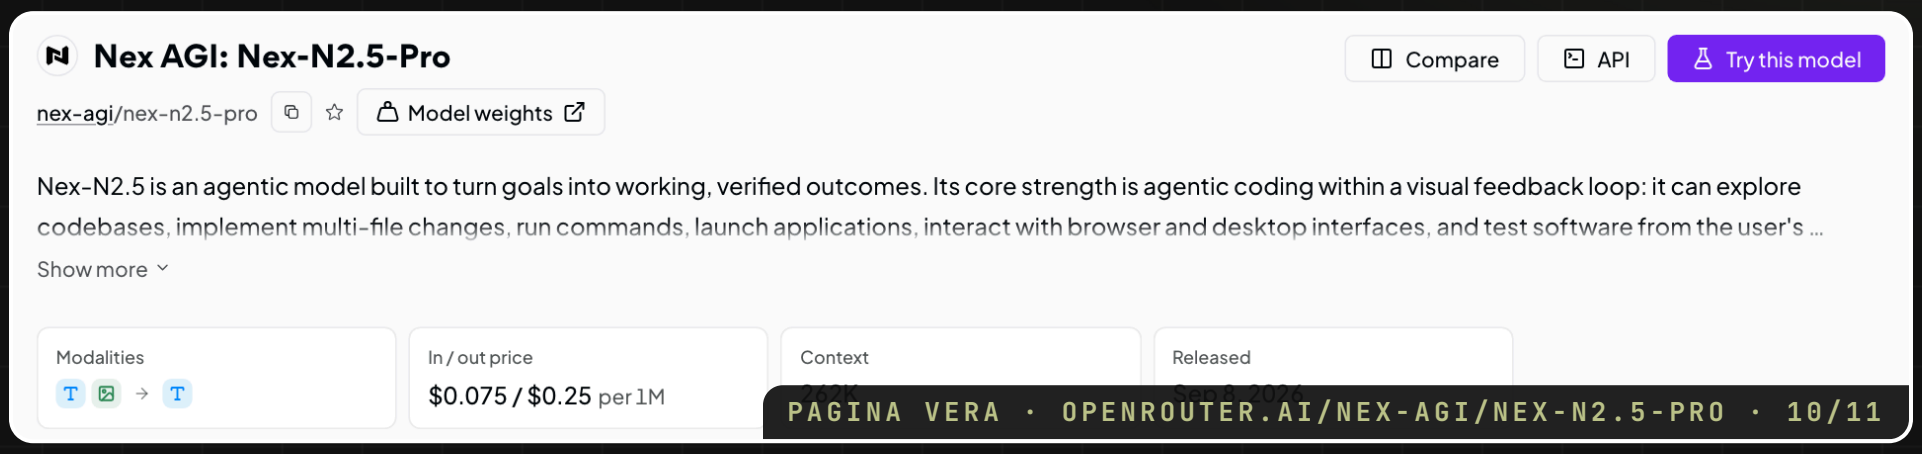
> **Errori comuni —** pensare che il «Max» dei benchmark sia quello che provi in chat: su OpenRouter ci sono solo **Pro e mini**, il Max per ora si usa solo scaricando i pesi.

FONTI · `huggingface.co/nex-agi/Nex-N2.5-Max` · `huggingface.co/collections/nex-agi/nex-n25`

// PASSO 02 · QUANTO COSTA DAVVERO

02 PESI GRATIS, *calcolo no.*

Perché: «gratis e open source» è vero per il file del modello. Per farlo rispondere servono GPU: o le paghi a consumo a qualcuno che lo ospita, o le hai tu.



Scaricare i pesi	Hugging Face o ModelScope	gratis
Pro su OpenRouter	per 1 milione di token in / out	$0.075 / $0.25
mini su OpenRouter	per 1 milione di token in / out	$0.025 / $0.10
mini / Pro in locale	GPU indicate nel model card	2 × H100 / 8 × H100
Max in locale	GPU indicate nel model card	2 nodi, 16 × H200

```
// ESEMPIO DI CONTO (prezzi veri, calcolo nostro)
1 domanda al Pro ≈ 2.000 token in + 1.000 token out
2.000 × $0,075/1M + 1.000 × $0,25/1M = $0,0004
1.000 domande così ≈ $0,40
```

01 Niente abbonamento, ma credito
OpenRouter funziona a credito prepagato in dollari: lo ricarichi e ogni richiesta scala il suo costo. All'acquisto del credito OpenRouter applica una commissione (FAQ ufficiale).

02 Il ragionamento si paga
I token del «pensiero» si pagano come output, e su OpenRouter il predefinito è ragionamento alto: per domande semplici spegnilo (pag. 05).

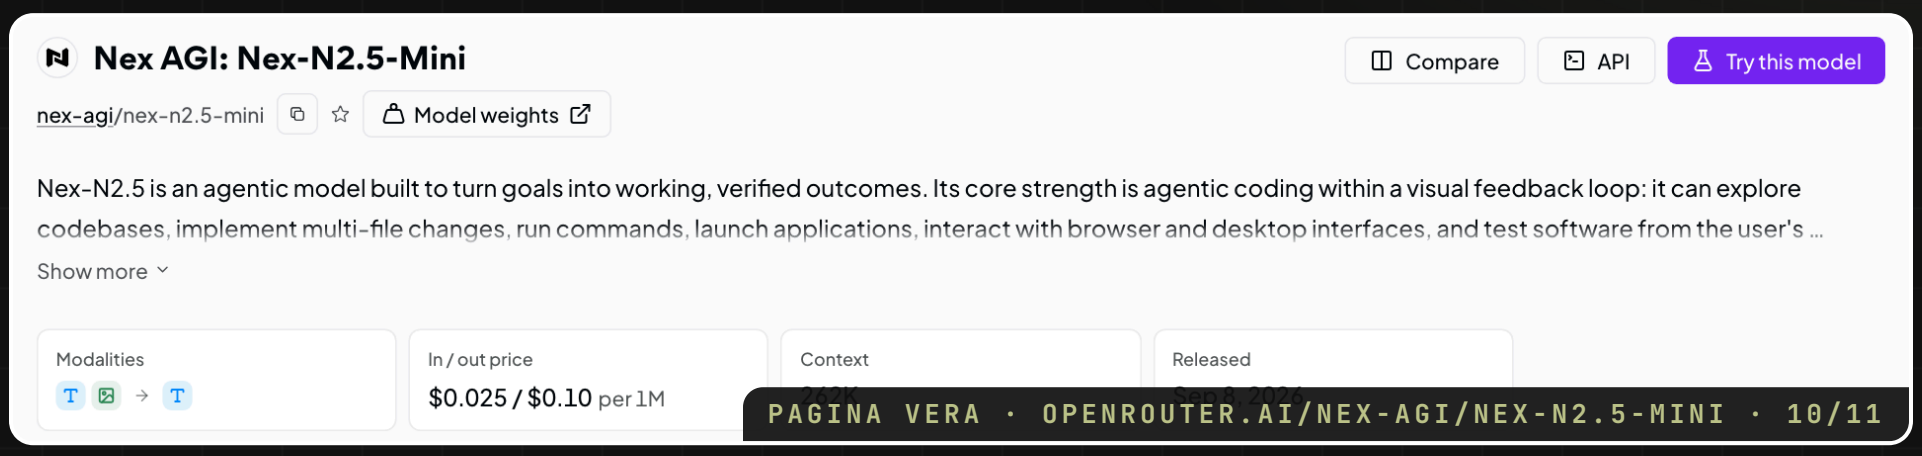
> **Errori comuni —** contare come una chat il lavoro di un agente: legge molte schermate e consuma molti più token.

FONTI · openrouter.ai/nex-agi/nex-n2.5-pro · openrouter.ai/nex-agi/nex-n2.5-mini · openrouter.ai/docs/faq

// PASSO 03 · PROVALO IN CHAT

03 LA PROVA PIÙ *veloce: chat.*

Perché: prima di scrivere codice o comprare hardware vuoi capire se il modello ti piace. La chat di OpenRouter te lo fa provare dal browser, senza scrivere codice.



01 **Crea l'account e aggiungi credito**
Su `openrouter.ai` registrati, poi in `openrouter.ai/settings/credits` ricarica il credito. Per le prove bastano pochi dollari (vedi il conto a pag. 03).

02 **Apri la pagina del modello**
`openrouter.ai/nex-agi/nex-n2.5-pro` (o `-mini`) e premi **Try this model** per scrivergli dal browser. Link diretto: `openrouter.ai/chat?models=nex-agi/nex-n2.5-pro`.

03 **Fai una domanda che conosci**
Usa un compito del tuo lavoro di cui sai già la risposta giusta: così giudichi la qualità, non la sensazione.

04 **Confrontalo**
Manda la stessa domanda anche al modello che usi oggi e metti le risposte una accanto all'altra: è il modo più onesto per decidere.

```
// PROMPT DI PROVA (da adattare · non eseguito: nessuna chiamata a pagamento per questa guida)
Ho questo elenco di 5 voli (incollato sotto). Ordinali dal più economico,
scarta quelli con più di uno scalo e dimmi quale prenderesti e perché,
in 5 righe al massimo.
```

> **Errori comuni —** aspettarsi che in chat «usi il computer»: la chat risponde solo con testo. L'uso del computer richiede un programma che gli passi le schermate e i comandi (pag. 07).

> **Consiglio —** il mini costa meno della metà del Pro: provali tutti e due sulla stessa domanda. Per compiti semplici spesso basta il mini.

FONTI · openrouter.ai/nex-agi/nex-n2.5-pro · openrouter.ai/settings/credits

// PASSO 04 · VIA API

04 UNA CHIAMATA, *dal terminale.*

Perché: con l'API metti Nex dentro i tuoi programmi e automazioni. OpenRouter usa lo stesso formato di OpenAI: chi ha già codice per GPT cambia solo indirizzo e nome del modello.

```
// 1 · LA CHIAVE (openrouter.ai/settings/keys)
export OPENROUTER_API_KEY=...   # la tua chiave, mai dentro il codice
```

```
// 2 · LA CHIAMATA (quickstart OpenRouter, cambiato il modello)
curl https://openrouter.ai/api/v1/responses \
  -H "Content-Type: application/json" \
  -H "Authorization: Bearer $OPENROUTER_API_KEY" \
  -d '{
  "model": "nex-agi/nex-n2.5-mini",
  "input": "Spiegami in 3 righe la licenza Apache 2.0",
  "reasoning": {"effort": "none"}
}'
```

```
// PRIMA DI SPENDERE (output vero 10/11, gratis, righe Nex filtrate)
$ curl -s https://openrouter.ai/api/v1/models     # senza chiave
nex-agi/nex-n2.5-mini  in 0.025  out 0.10  tools: no   input: text, image
nex-agi/nex-n2.5-pro   in 0.075  out 0.25  tools: sì   input: text, image
```

01 In Python
Stessa pagina: l'SDK di OpenAI con `base_url="https://openrouter.ai/api/v1"` e la tua chiave; cambia solo `model="nex-agi/nex-n2.5-pro"`.

02 Ragionamento acceso o spento
Nex accetta `none`, `medium` e `high` (predefinito su OpenRouter: `high`). `"effort": "none"` risponde subito e costa meno.

03 Pro se ti servono gli strumenti
Oggi su OpenRouter solo il Pro accetta `tools` (le funzioni che un agente chiama). Il mini no: per un agente parti dal Pro.

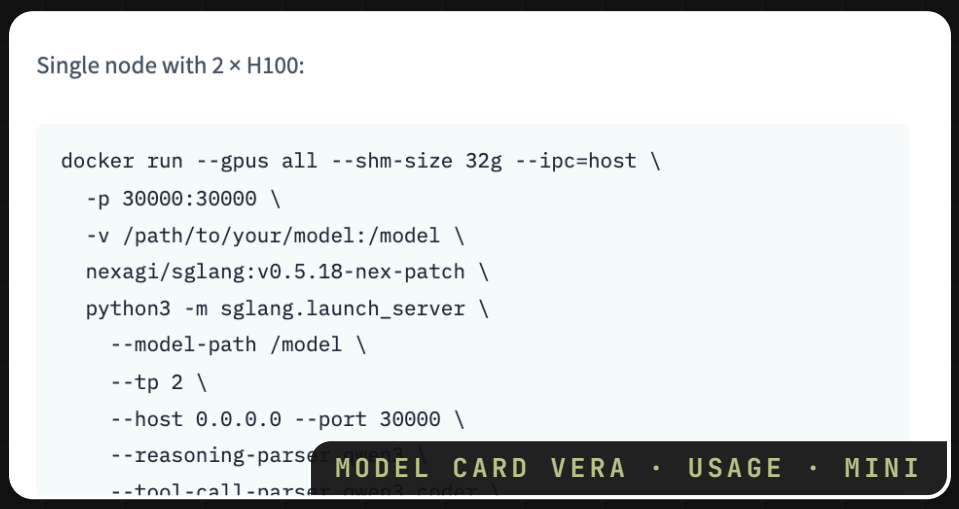
> **Errori comuni —** errore 401 = chiave sbagliata o non esportata nel terminale; 402 = credito insufficiente (doc errori OpenRouter). Nome del modello scritto a mano: copialo dalla pagina, va tutto minuscolo.

FONTI · openrouter.ai/docs/quickstart · openrouter.ai/docs/guides/best-practices/reasoning-tokens

// PASSO 05 · FARLO GIRARE TUO

05 IN LOCALE SERVE *un data center.*

Perché: con i pesi sul tuo server non paghi a token e i dati non escono. Ma il model card documenta un solo modo, e servono GPU professionali anche per il mini.



01 **Un solo metodo documentato**
Docker con lo **SGLang** modificato da Nex. Ollama, llama.cpp, vLLM: nel model card **non trovati** per N2.5, quindi niente comandi inventati.

02 **GPU indicate**
mini 2 × H100 · Pro 8 × H100 · Max 2 nodi con 16 × H200.

// 1 · SCARICA (CLI ufficiale Hugging Face)

```
# prova: un solo file piccolo
uvx hf download nex-agi/Nex-N2.5-mini config.json --local-dir ./nex
# tutto il modello (circa 70 GB)
uvx hf download nex-agi/Nex-N2.5-mini --local-dir ./nex
```

// COSA DEVI VEDERE (output vero, 10/11, primo comando)

```
path=nex/config.json     (dentro: 256 esperti, 8 per token, contesto 262.144)
```

// 2 · AVVIA IL SERVER (model card, Nex-N2.5-mini)

```
docker run --gpus all --shm-size 32g --ipc=host -p 30000:30000 \
  -v /path/to/your/model:/model nexagi/sglang:v0.5.18-nex-patch \
  python3 -m sglang.launch_server --model-path /model --tp 2 \
  --host 0.0.0.0 --port 30000 --reasoning-parser qwen3 \
  --tool-call-parser qwen3_coder \
  --chat-template /path/to/nex-N2.5-mini/chat-template.jinja \
  --mamba-scheduler-strategy extra_buffer
```

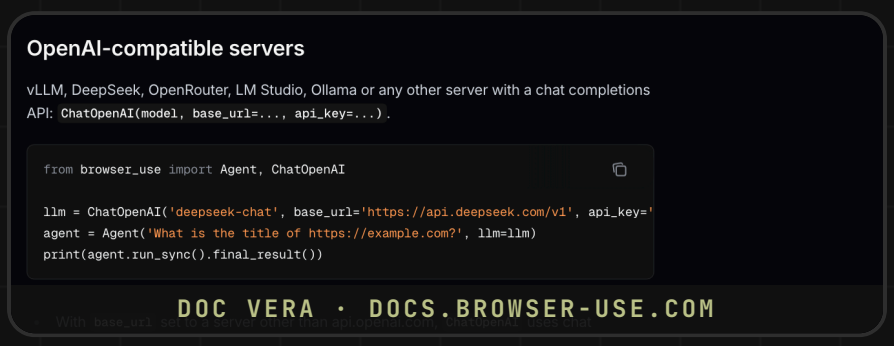
> **Errori comuni —** avviare senza GPU NVIDIA o con meno GPU di quelle indicate. Nel repo il template si chiama `chat_template.jinja`: correggi il percorso del comando.

FONTI · huggingface.co/nex-agi/Nex-N2.5-mini · huggingface.co/docs/huggingface_hub/guides/cli · hub.docker.com/r/nexagi/sglang

// PASSO 06 · COME AGENTE CHE USA IL COMPUTER

06 L'AGENTE: COSA C'È, *cosa manca.*

Perché: è la promessa del reel. Il modello è addestrato a usare computer e browser, ma per farlo serve un programma che gli mostri lo schermo ed esegua i suoi clic. Ecco la situazione vera al 10/11/2026.



01 Lo strumento di Nex: non ancora pubblico

I punteggi di uso del computer del model card sono misurati con **NexCUA**, che «sarà open source a breve». Oggi non l'abbiamo trovato pubblicato, e le pagine GitHub di nex-agi linkate nel model card non si aprivano.

02 Intanto: browser-use (trovato da noi)

Libreria Python open source (MIT) che fa guidare un browser vero a un modello. La sua documentazione supporta OpenRouter e qualsiasi server compatibile OpenAI. Controlla **solo il browser**, non tutto il desktop.

```
// ESEMPIO (forme della doc browser-use, modello cambiato · non eseguito da noi)
pip install 'browser-use==1.0.0'        # Python 3.11+

import asyncio, os
from browser_use import Agent, Browser, ChatOpenAI
llm = ChatOpenAI('nex-agi/nex-n2.5-pro', base_url='https://openrouter.ai/api/v1',
                 api_key=os.environ['OPENROUTER_API_KEY'], reasoning_effort='medium')
async def main():
    agent = Agent('Qual è il titolo di https://example.com?', llm=llm,
                  browser=Browser('chromium'))   # Chrome locale, profilo temporaneo
    print((await agent.run()).final_result())
asyncio.run(main())
```

Errori comuni — dargli il tuo browser con password salvate: parti da un profilo vuoto e da siti innocui. E usa il **Pro**: il mini su OpenRouter non accetta strumenti.

Consiglio — la doc di browser-use dice di fissare la versione con `==`: esce spesso una versione nuova che può rompere il codice. Ogni esecuzione riporta il costo del modello in `result.cost_usd`.

FONTI · docs.browser-use.com/open-source/quickstart · github.com/browser-use/browser-use

// PASSO 07 · LEGGERE I BENCHMARK

07 «BATTE GPT-5.6»: *cosa vuol dire.*

Perché: il reel dice che nei test di Nex il modello batte GPT-5.6 su più di metà dei benchmark. È vero nei loro numeri: il Max supera GPT-5.6 Sol in **5 test su 8**. Ma è bene sapere chi ha misurato cosa.

Benchmark	Nex-N2.5-mini	Nex-N2.5-Pro	Nex-N2.5-Max	Claude Opus 5	GPT-5.6 Sol	Kimi-K3	GLM-5.3	DeepSeek-V4-Pro-0813[4]	Qw Ma
CODING[3]									
Terminal-Bench 2.1	73.4	82.7	86.1	**89.1**	88.8	88.3	88.2	87.9	86.
SWE-Bench Pro	43.8	61.2	65.7	**79.2**	64.6	63.3	64.6	55.4	67.
DeepSWE v1.1	36.1	55.8	65.6	**73.7**	72.7	67.5	66.9	62.8	69.
AGENTIC									
AutomationBench v1.0.6[5]	32.3	44.2	50.2	**50.3**	45.8	46.7	48.2	43.2	39.
Toolathlon Verified	54.6	68.5	74.7	**76.5**	74.9	**76.5**	73.0	74.1	72.
GDPval-AA v2	1446	1628	1713	**1831**	1711	1675	1763	1580	171
Job Bench	28.5	41.4	53.6	**65.7**	45.4	52.9	58.2	54.1	53.
BrowseComp[6]									

TABELLA VERA · MODEL CARD

BENCHMARK	Max · GPT · Opus	MAX VS GPT
Terminal-Bench 2.1	86.1 · 88.8 · 89.1	perde
SWE-Bench Pro	65.7 · 64.6 · 79.2	vince
DeepSWE v1.1	65.6 · 72.7 · 73.7	perde
AutomationBench	50.2 · 45.8 · 50.3	vince
Toolathlon Verified	74.7 · 74.9 · 76.5	perde
GDPval-AA v2	1713 · 1711 · 1831	vince
Job Bench	53.6 · 45.4 · 65.7	vince
BrowseComp	92.6 · 90.4 · 90.8	vince

01 Dichiarati dal produttore
Dove esistono, i punteggi degli altri modelli vengono da classifiche e report ufficiali; gli altri sono test fatti da Nex. I punteggi di uso del computer usano NexCUA, che non è pubblico: oggi nessuno può rifarli.

02 Nella stessa tabella c'è chi fa meglio
Claude Opus 5 ha il punteggio più alto (o pari) in 7 benchmark su 8; contro Opus il Max vince solo BrowseComp.

03 Il Max non è quello che provi
I numeri sopra sono del Max (solo testo, solo pesi). Su OpenRouter ci sono Pro e mini, con punteggi più bassi nella stessa tabella.

> **Errori comuni —** scegliere un modello solo dalla tabella. Il test che conta è il tuo: la stessa domanda del tuo lavoro a due modelli (pag. 04).

> **Consiglio —** quando leggi «batte X», cerca nella tabella tre cose: quale versione del modello (qui il Max), chi ha misurato (qui Nex) e con quale strumento (qui NexCUA o NexAU, note in fondo al model card).

FONTI · huggingface.co/nex-agi/Nex-N2.5-Max

// PASSO 08 · LA VERIFICA

08 COME SAI *che funziona.*

Perché: una risposta che «suona bene» non vuol dire che il modello sia quello giusto, né che l'agente abbia fatto davvero quello che dice. Controlla questi punti, in ordine.

Il modello giusto	openrouter.ai/activity: storico dell'uso, filtrabile per modello	pag. 05
Il costo vero	il credito che scende dopo le tue prove, su Activity	pag. 03
La qualità	la stessa domanda nota a Nex e al tuo modello attuale	pag. 04
Gli strumenti	con tools, la risposta deve chiamare la funzione giusta	pag. 05
L'agente	controlla tu il risultato sul sito, non solo il suo «fatto»	pag. 07

01 Fai un test con risposta nota
Un elenco di 10 righe da ordinare, un calcolo, un riassunto di un testo che conosci. Se sbaglia lì, non affidargli compiti più lunghi.

02 Per l'agente: verifica fuori dall'agente
La doc di browser-use lo dice chiaramente: il «successo» è il verdetto che dà il modello stesso. Le azioni importanti (un modulo inviato, una prenotazione) vanno controllate a parte.

03 Tieni d'occhio i token
Un agente manda al modello una schermata a ogni passo: guarda il costo dei primi 3-4 compiti prima di lasciarlo lavorare da solo.



REEL · SCENA ILLUSTRATIVA

// PRIMA DI DISDIRE UN ABBONAMENTO

Il reel mostra un abbonamento annullato: fallo solo dopo una settimana di prova sui tuoi compiti veri, con il costo di OpenRouter misurato. Per molti l'abbonamento resta più comodo; per chi lavora via API o in automazione, **il consumo a token può costare molto meno**.

> **Consiglio —** salva le tue 5 domande di prova in un file: quando esce un modello nuovo le rilanci identiche e confronti in 10 minuti.

FONTI · openrouter.ai/activity · docs.browser-use.com/open-source/quickstart

// LINK UFFICIALI

TUTTO QUELLO CHE TI *serve.*

Pagine ufficiali e documentazioni, aperte e controllate il 10/11/2026.

Nex-N2.5-Max (model card)	huggingface.co/nex-agi/Nex-N2.5-Max	01 07
Nex-N2.5-Pro	huggingface.co/nex-agi/Nex-N2.5-Pro	01
Nex-N2.5-mini	huggingface.co/nex-agi/Nex-N2.5-mini	01 05
Sito Nex-AGI	nex-agi.com	01
Nex N2.5 Pro su OpenRouter	openrouter.ai/nex-agi/nex-n2.5-pro	02 03
Nex N2.5 mini su OpenRouter	openrouter.ai/nex-agi/nex-n2.5-mini	02 03
Credito e chiavi OpenRouter	openrouter.ai/settings/credits	03 04
Quickstart API OpenRouter	openrouter.ai/docs/quickstart	04
Ragionamento (effort)	openrouter.ai/docs/guides/best-practices/reasoning-tokens	04
CLI Hugging Face	huggingface.co/docs/huggingface_hub/guides/cli	05
Immagine Docker SGLang di Nex	hub.docker.com/r/nexagi/sglang	05
browser-use (MIT)	github.com/browser-use/browser-use	06
browser-use con OpenRouter	docs.browser-use.com/supported-models	06
Attività e costi	openrouter.ai/activity	08

// COSA COSTA

Pesi Nex N2.5	licenza Apache 2.0, download	gratis
OpenRouter	credito prepagato, a token	pochi centesimi a prova
In locale	GPU da data center (min. 2 × H100)	hardware tuo
browser-use	libreria open source, browser locale	gratis + token

// RICORDA

«Gratis» è il modello, non il lavoro che fa: **ogni risposta costa calcolo**, pagato a token o col tuo hardware. I benchmark sono di Nex e lo strumento con cui ha misurato l'uso del computer non è ancora pubblico: fidati dei tuoi test, non della tabella.

Un agente che usa il computer fa clic veri: dagli siti e account di prova, controlla quello che fa e non lasciargli pagamenti o password finché non l'hai visto lavorare. Se un comando è cambiato, vale la pagina ufficiale.