

JARVIS V2 com'è fatto

Il cruscotto che hai visto nel reel non è un mockup. È una pagina che gira sul mio Mac, ascolta con Whisper in locale, risponde con una voce sintetizzata in locale, e smista ogni richiesta su tre livelli diversi a seconda di quanto lavoro serve davvero.


Questa nota sta in quattro pagine e spiega il meccanismo, non il codice: cosa fa ogni pezzo, perché esiste, e cosa serve per rifarselo.

La cosa che conta

Quasi tutti gli "assistenti AI" mandano ogni singola domanda a un modello grosso. Costa, è lento, e soprattutto è inutile: **la maggior parte delle domande che fai in una giornata ha già la risposta scritta da qualche parte.** Il punto di JARVIS è decidere, ogni volta, se serve davvero un modello.

LO SCHEMA

Una richiesta, un router, tre livelli, una memoria sola



Il pezzo che fa la differenza è **JEV**: sta in mezzo e decide. Non è intelligenza, è smistamento — ed è proprio per questo che funziona.

I TRE LIVELLI

Perché quasi nulla arriva a un modello

LIVELLO 1 · ISTANTANEO

Regole e dati già salvati

"Quali sono le mie priorità di oggi", "che c'è in agenda", "quanti iscritti ho", "cosa ho fatto ieri". La risposta è già scritta nelle note e nel cruscotto: la legge e te la dice. **Nessun modello, nessun costo, nessuna attesa.** È il livello che copre la maggior parte delle domande di una giornata normale.

LIVELLO 2 · QUALCHE SECONDO

Un modello piccolo e veloce

Quando serve ragionare un minimo ma non lavorare — riassumere le notizie del giorno, rispondere a qualcosa che non è già scritto da nessuna parte. Gli arriva la domanda insieme al contesto del cruscotto, così risponde su dati veri e non se li inventa.

LIVELLO 3 · IN BACKGROUND

Apri un terminale e lavora

"Cerca cosa hanno lanciato i competitor", "preparami il preventivo per quel cliente". Qui non ti risponde subito: apre un terminale Claude Code o Codex, oppure lancia una delle skill, e ti lascia il report nel vault quando ha finito. **Te ne accorgi dopo, non aspetti davanti allo schermo.**

Il vault è la memoria, non un archivio

Tutti e tre i livelli leggono dalla stessa cartella e ci scrivono dentro: note giornaliere, report, ricerche, conversazioni, e la ricevuta di ogni singola richiesta. È la stessa cartella che apro in Obsidian. Per questo il livello 1 può rispondere senza modello: **la risposta l'ha scritta il livello 3 ieri.**

VOCE, SKILL, E COSA SERVE

Ascolta e parla senza uscire dal computer

Whisper

Gira in locale sul Mac (mlx-whisper su Apple Silicon). Tieni premuta la barra spaziatrice, parli, ti fermi: rileva la pausa e invia da solo. L'audio non esce dal computer.

La voce

Sintetizzata in locale — Kokoro se installato, altrimenti le voci di sistema di macOS. Nessuna chiave API, nessuna chiamata di rete per parlare.

21 skill che lavorano mentre fai altro

Plan Today, Inbox Brief, Deep Research, Content Cascade, YT Pipeline, Competitor Scan, Hook Workshop, Vault Cleanup... si lanciano dal cruscotto o a voce, girano in background e scrivono il risultato nel vault. Sono la ragione per cui il livello 3 ha senso: il lavoro lo fanno loro, non tu.

Cosa serve per rifarlo

Un Mac, Python, un modello Whisper in locale e una pagina HTML. Il resto — quali dati legge, quali skill esistono, cosa finisce nel vault — dipende da come lavori tu, ed è la parte che va cucita addosso. Il meccanismo è quello dello schema a pagina 2: quello si copia.

● **SCRIVIMI SU @21STUDIO.IO**